

UNIVERSIDAD DE SAN CARLOS DE GUATEMALA

FACULTAD DE INGENIERIA

ESCUELA DE CIENCIAS

SEMINARIO DE SISTEMAS 2

SECCION A



ANALISIS INDUSTRIAS METALMECÁNICAS DEL NORTE

NOMBRE: MÁDELYN ZUSETH PÉREZ ROSALES

CARNE: 201612558

GUATEMALA, 21 DE JUNIO DEL 2026

INTRODUCCIÓN

A continuación se encuentra un análisis Industrias Metalmecánicas del Norte donde se implementó una red de sensores IoT que monitorea el estado operativo de las máquinas que operan en el lugar. El objetivo de este análisis es realizar un plan de limpieza, transformar y explorar los datos recopilados por dichos sensores para identificar patrones asociados a fallos y apoyar la identificación de patrones que permitan anticipar posibles fallos en las máquinas. El archivo a analizar contiene 10,000 registros y variables relacionados con temperatura, velocidad de rotación, torque, desgaste de herramientas y tipos de fallos.

DATASET

- Características del DataSet

Característica	Valor
Registros	10,000
Variables	10
Tipo de Análisis	Mantenimiento Predictivo
Variable Objetivo	Target

- Diccionario Resumido

Variable	Descripción
Type	Tipo de máquina
Air temperatura [K]	Temperatura ambiente
Process temperature [K]	Temperatura de proceso
Totational speed [rpm]	Velocidad de rotación
Torque [Nm]	Torque
Tool wear [min]	Desgaste de herramienta
Target	Indica fallo (0/1)
Failure Type	Tipo de fallo

Imagen 1: Datos Iniciales

	UDI	Product ID	Type	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Target	Failure Type
0	1	M14860	M	298.1	308.6	1551	42.8	0	0	No Failure
1	2	L47181	L	298.2	308.7	1408	46.3	3	0	No Failure
2	3	L47182	L	298.1	308.5	1498	49.4	5	0	No Failure
3	4	L47183	L	298.2	308.6	1433	39.5	7	0	No Failure
4	5	L47184	L	298.2	308.7	1408	40.0	9	0	No Failure

Fuente: Elaboración propia con datos del dataset *Predictive Maintenance Dataset* obtenido de Kaggle

DATA CLEANING


- **Data de problemas Encontrados**

Problema	Solución
Espacios en columnas	Str.strip()
Duplicados	Drop_duplicates()
Valores faltantes	Validación e imputación
Categorías inconsistentes	Normalización de texto
Valores fuera de rango	Filtrado
Variable Target inválida	Validación binaria
Duplicados semánticos	Eliminación por atributos
Outliers	Método IQR

Conclusión:


Como parte del proceso de limpieza de datos, se realizó diversos procesos de limpieza, validación y normalización para asegurar una buena calidad de información utilizada en el análisis. Se identificó la presencia de valores nulos, registros duplicados, inconsistencias en variables categóricas y posibles anomalías en los datos numéricos. También se verificó que los valores se encuentran dentro de rangos razonables de operación. Este proceso permitió contar con un conjunto de datos más consistentes y confiable para el desarrollo del análisis exploratorio.

HISTOGRAMAS Y DISTRIBUCIÓN



Los histogramas muestran la frecuencia de los valores registrados en cada variable. Las temperaturas presentan una distribución estable, mientras que la velocidad de rotación, el torque y el desgaste de herramienta muestran una mayor variabilidad. La variable Target indica que predominan los registros sin fallo.

MAPA DE CORRELACIÓN



El mapa de correlación muestra la relación entre las variables operativas de las máquinas. Se observa una correlación positiva entre la temperatura ambiente y la temperatura de proceso, mientras que las demás variables presentan correlaciones bajas o moderadas. Esto sugiere que cada sensor aporta información distinta sobre el estado de la máquina, lo que resulta útil para el monitoreo y la detección temprana de posibles fallos.

EXPLICACIÓN DE CODIGO

Importación de librerías

Se importaron las librerías necesarias para el desarrollo del proyecto. Pandas y NumPy fueron utilizadas para la manipulación y transformación de los datos, Matplotlib y Seaborn para la generación de visualizaciones estadísticas, y la librería os para la gestión de archivos y directorios dentro del proyecto.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import os
```

Carga del Dataset

Se cargó el conjunto de datos desde un archivo CSV y se realizó una inspección inicial para conocer su estructura. Se verificó la cantidad de registros y columnas, los tipos de datos presentes, las estadísticas descriptivas básicas y la existencia de valores faltantes.

```
df = pd.read_csv("../datos/predictive_maintenance.csv")

print("Dimensiones iniciales:", df.shape)
display(df.head())
df.info()
display(df.describe())
display(df.isnull().sum())
```

Creación de una copia de trabajo

Se creó una copia del dataset original con el objetivo de preservar la información fuente y realizar todas las transformaciones sobre una versión independiente.

```
df_limpio = df.copy()
```

Limpieza de nombre de columnas

Se eliminaron espacios en blanco innecesarios en los nombres de las columnas para evitar errores durante el acceso y manipulación de las variables.

```
df_limpio.columns = df_limpio.columns.str.strip()
```

Identificación y eliminación de duplicados

Se identificaron registros completamente duplicados dentro del conjunto de datos y posteriormente fueron eliminados para evitar sesgos en el análisis.

```
duplicados = df_limpio.duplicated().sum()
print("Duplicados exactos encontrados:", duplicados)
df_limpio = df_limpio.drop_duplicates()
print("Valores faltantes por columna:")
```

Detección de valores atípicos

Se implementó el método del Rango Intercuartílico (IQR) para identificar valores atípicos en las principales variables numéricas. Este procedimiento permite detectar observaciones significativamente alejadas del comportamiento normal de los datos.

```
for col in variables_outliers:
    detectar_outliers_iqr(df_limpio, col)
```

Análisis de valores faltantes

```
sns.heatmap(df_limpio.isnull(), cbar=False)
```

Se utilizó un mapa de calor para visualizar la presencia de valores faltantes dentro del conjunto de datos y verificar la efectividad del proceso de limpieza.

Mapa de correlación

El mapa de correlación facilitó la interpretación visual de las relaciones entre variables, permitiendo identificar asociaciones positivas y negativas.

```
plt.figure(figsize=(10, 5))
sns.countplot(y="Failure Type", data=df_limpio)
```

APENDICE

Link del repositorio a utilizar en el cual se encuentra el código y los archivos a analizar y el resultado de los archivos limpios:

https://github.com/MadelynPerez1996/Tarea_Segundo_Parcial_201612558.git

